

# Predicción de cuellos de botella mediante una red neuronal: caso de simulación de un sistema de manufactura

Priscila Arrieta Salazar<sup>1</sup>, Nicolás Cortés Malaspina<sup>2</sup>, María Laura Jiménez Elgarrista<sup>3</sup>,  
Treisy Vargas Morales<sup>4</sup>

Escuela de Ingeniería Industrial, Universidad de Costa Rica

[priscila.arrieta@ucr.ac.cr](mailto:priscila.arrieta@ucr.ac.cr)<sup>1</sup>, [nicolas.cortes@ucr.ac.cr](mailto:nicolas.cortes@ucr.ac.cr)<sup>2</sup>, [maria.jimenezelgarrista@ucr.ac.cr](mailto:maria.jimenezelgarrista@ucr.ac.cr)<sup>3</sup>, ,  
[treisy.vargas@ucr.ac.cr](mailto:treisy.vargas@ucr.ac.cr)<sup>4</sup>

## Resumen

El presente estudio propone un modelo predictivo para identificar cuellos de botella dinámicos en sistemas de manufactura, combinando simulación en Arena con una red neuronal densa. A partir de los datos simulados, se calcula el índice de cuello de botella (BI) para las estaciones y se entrena una red para predecir su comportamiento en el tiempo. El modelo logró un error absoluto medio de 0.00939, mostrando alta precisión en contextos de manufactura multivariantes y dinámicos. Esta metodología supera las limitaciones de los modelos estadísticos tradicionales, permitiendo una gestión proactiva y adaptable en entornos industriales complejos.

## Palabras Clave:

Cuellos de botella, series de tiempo, orientado a datos, redes neuronales, modelos predictivos.

## Abstract

*This study proposes a predictive model to identify dynamic bottlenecks in manufacturing systems by combining Arena simulation with a dense neural network. Through simulated data, the Bottleneck Index (BI) is calculated, and the network is trained to predict its behavior over time. The model achieved a mean absolute error of 0.00939, showing high accuracy in multivariable and dynamic manufacturing contexts. This methodology overcomes the limitations of traditional statistical models, which enables adaptable and proactive management in complex industrial environments.*

## Key Words:

*Bottleneck, time series, data-driven, neural networks, predictive models.*

## 1. Introducción

En los entornos productivos de alta complejidad, variabilidad y mezcla de factores; la apropiada detección y gestión de los cuellos de botella figura como un pilar estratégico en la eficiencia y excelencia operativa industrial. A lo largo de los años, los métodos tradicionales para su identificación y abordaje han sido de carácter estadístico estático que, a pesar de ser confiables, presentan limitaciones al integrar dinámicas transitorias, variabilidad de productos y distribuciones estadísticas diversas. En respuesta, la proliferación de técnicas de Inteligencia Artificial para la gestión de estos escenarios ofrece una herramienta para la superación de estas limitaciones, además de corresponder a un espacio fértil para el alcance progresivo de una gestión proactiva y predictiva de las restricciones del sistema.

El presente artículo propone un enfoque que integra la simulación de sistemas de manufactura en el software Arena con un modelo de redes neuronales densas (RND) para la predicción del índice de cuello de botella en escenarios con incertidumbre multivariable. Es decir, esta red neuronal predice y analiza la existencia de cuellos de botella y su posible dinamismo a lo largo del tiempo mediante los datos simulados como insumo para obtener un sistema de monitoreo inteligente adaptable a la variabilidad operacional.

### 1.1. Objetivo

Desarrollar y evaluar un modelo basado en redes neuronales densas (RND) que permita predecir dinámicamente los cuellos de botella en líneas de producción seriales, utilizando una simulación en Arena versión 16.20.00 con un sistema de incertidumbre multivariable.

## **2. Revisión de Literatura**

El presente estado del arte tiene como propósito ofrecer un panorama general que inicia con el análisis del desempeño en sistemas complejos, continúa con el estudio de los cuellos de botella en sistemas dinámicos, aborda los métodos estadísticos utilizados y culmina con la aplicación de inteligencia artificial en la predicción de series de tiempo, todo ello a partir de una revisión documental de diversos artículos científicos.

### **2.1. Desempeño en sistemas complejos y análisis del throughput**

En la actualidad, los sistemas de manufactura pueden entenderse como sistemas complejos, estocásticos y dinámicos. La complejidad se manifiesta en la diversidad de configuraciones posibles con características de flujo particulares que afectan el comportamiento y desempeño global del sistema. La inherente variabilidad estocástica de los procesos industriales provoca que indicadores como los tiempos de ciclo de las estaciones o la disponibilidad de recursos no sean constantes, sino que varían debido a múltiples factores operativos (Lai et al., 2021). A ello se le suma la dinámica a la que están sujetos estos sistemas, donde eventos no previstos pueden desestabilizar rápidamente una programación previamente establecida (Frazzon et al., 2018).

En este contexto, el throughput, entendido como la tasa de producción efectiva de productos terminados, se convierte en un indicador fundamental para evaluar el desempeño global del sistema. Según la Teoría de Restricciones, propuesta por Goldratt (2004), el throughput no solo mide la eficiencia interna, sino que refleja la capacidad del sistema para adaptarse a la demanda real del mercado, integrando la dimensión económica con la operativa. En sistemas complejos y dinámicos, este indicador está condicionado por la aparición de cuellos de botella, es decir, aquellos recursos o procesos que limitan el flujo global de producción y, por lo tanto, restringen la capacidad del sistema (Iravani, 2021).

### **2.2. Cuellos de botella en sistemas dinámicos: identificación y predicción**

La gestión de los cuellos de botella en sistemas de producción ha evolucionado desde enfoques estáticos centrados en la capacidad, a métodos que consideran su comportamiento dinámico. En un enfoque inicial, Goldratt (2004) en su libro “The Goal”, definió el cuello de botella como el punto de menor capacidad frente a la demanda, convirtiéndose en la principal restricción del flujo productivo. Más adelante, Hopp y Spearman (2008) ampliaron esta visión, al considerar que un recurso altamente utilizado puede generar acumulaciones de inventario por encima del nivel crítico, forzando al sistema a operar por debajo de su manera óptima, lo que implica que no siempre coincide con el recurso de menor capacidad. Por esto, su identificación y gestión figuran como acciones esenciales para la mejora de la eficiencia de los sistemas de manufactura (Roser et al., 2002).

En sistemas caracterizados por alta variabilidad y complejidad, los cuellos de botella tienen la tendencia a ser dinámicos por lo que migran entre recursos con el paso del tiempo (Li et al., 2009). Esta variabilidad se ve influida por factores como los cambios en los tiempos de procesamiento, la gestión de buffers, las interrupciones aleatorias y las políticas de control de producción (Roser et al., 2002). Esto limita la efectividad de los métodos tradicionales, que, si bien son adecuados para detectar y analizar cuellos de botella estáticos, resultan insuficientes para contextos transitorios donde la detección y anticipación representa un desafío mayor.

En este contexto, la literatura reciente ha destacado la importancia de predecir no solo los cuellos de botella actuales, sino también aquellos que pueden llegar a surgir en el futuro, especialmente en sistemas sujetos a alta variabilidad e incertidumbre (Tang et al., 2024). Entre las métricas desarrolladas para esto, destaca el índice de cuello de botella o Bottleneck Index (BI, por sus siglas en inglés) el cual permite identificar y cuantificar los cuellos de botella bajo condiciones dinámicas. Este índice se calcula a partir de variables operativas como tiempos de producción y utilización de estaciones. Lo cual facilita la comparación entre recursos y la detección dinámica del recurso que más restringe el throughput global (Xue et al., 2022).

### **2.2. Métodos estadísticos y métodos impulsados por datos (data-driven methods)**

El análisis y predicción de cuellos de botella en líneas de producción se ha formado por métodos estadísticos tradicionales, surgen para representar procesos estocásticos específicamente lineales con datos históricos como insumo (Box et al., 2015). Estos modelos parten de supuestos específicos para su funcionamiento, la estacionariedad mencionada anteriormente representa uno de ellos, es decir, requiere que la serie de tiempos se mantenga estacionaria y asume una relación lineal de los datos (Hyndman & Athanasopoulos, 2021). Por esto, su aplicación en un escenario con sistemas complejos y reales de manufactura representa un reto ya que rara vez sus datos poseen estacionariedad. Asimismo, estos modelos estadísticos son univariantes por lo que tienen la capacidad de solo modelar una variable a la vez, lo cual representa otra limitante ante escenarios complejos y reales ya que modelos como estos no toman en

cuenta la interacción entre máquinas donde múltiples estaciones, productos o rutas de procesamiento interactúan simultáneamente y no pueden adaptarse a cambios dinámicos en el entorno de producción (Xue et al., 2022). A esto se le agrega su naturaleza lineal, que impide representar adecuadamente relaciones no lineales o efectos acumulativos entre entradas y salidas del sistema (Subramaniyan et al., 2021).

En respuesta a estas limitaciones, se introducen los métodos impulsados por datos o conocidos en inglés como *data-driven methods*; una evolución en las metodologías de identificación y predicción de cuellos de botella. Su principal ventaja yace en la capacidad de aprender patrones derivados de los datos simulados o históricos de entrada sin la necesidad de estrechos supuestos estadísticos para la estructura de los datos; estos se aplican a través de técnicas como modelos de clustering, árboles de decisión o redes neuronales (Lepeniotti et al., 2020). Específicamente, las redes neuronales recurrentes representan las principales ventajas para el provechoso estudio de contextos multivariantes, así como estudiar dinámicas temporales en sistemas industriales, identificar relaciones no lineales y adaptarse a patrones dinámicos (Subramaniyan et al., 2018).

## **2.3. Inteligencia Artificial en predicción de series de tiempo**

Los modelos predictivos basados en datos han emergido como una estrategia poderosa para detectar dinámicamente cuellos de botella en sistemas productivos complejos. A diferencia de enfoques deterministas como el *Shifting Bottleneck Method* (Método de Cuello de Botella Móvil), los modelos predictivos permiten capturar variabilidad y dependencia temporal en los procesos, ofreciendo diagnósticos proactivos en lugar de retrospectivos (Lai et al., 2021). Esto es especialmente relevante en líneas de producción seriales con múltiples estaciones interdependientes. Una de las técnicas más prometedoras es el uso de algoritmos de aprendizaje automático que son alimentados por datos operativos como tiempo de ciclo, utilización de recursos y tasas de rechazos (West et al., 2023). Además, los modelos predictivos pueden ser adaptados a entornos con datos limitados mediante estrategias como el aprendizaje incremental o la transferencia de conocimiento entre líneas similares (Lepeniotti et al., 2020).

Además, las redes neuronales se han consolidado como herramientas potentes para el análisis de series temporales en entornos industriales. Una serie de tiempo se define como una sucesión de datos recolectados en intervalos regulares, en la que el orden de observación es esencial para identificar patrones y realizar predicciones. Esta característica temporal hace que las RN sean especialmente útiles para modelar relaciones no lineales y dependencias secuenciales, permitiendo anticipar eventos como fallos, cuellos de botella o disminuciones en el rendimiento operativo (Lepeniotti et al., 2020).

## **3. Metodología**

1. Utilizar el software Arena para construir un modelo de simulación de manufactura. Este modelo debe replicar el flujo de trabajo, la lógica de procesamiento y tiempos asociados a cada estación, para esto se utiliza una base de datos la cual se puede encontrar en el Anexo 2.
2. Calcular el valor del BI en los intervalos de tiempo definidos. Este índice permite identificar la estación que limita el rendimiento del sistema en cada momento.
3. Tratar la serie de valores del BI como una serie temporal, de manera que se pueda analizar la evolución del cuello de botella a lo largo del tiempo.
4. Predecir el valor futuro del BI para cada estación utilizando una RN. Comparar los vectores predichos obtenidos mediante la simulación en Arena, evaluando su precisión y capacidad de ajuste.
5. Validar la metodología propuesta mediante un caso industrial real comprobando si el enfoque predictivo permite anticipar correctamente la aparición de cuellos de botella.

### **3.1 Análisis cuellos de botella dinámicos del sistema utilizando Arena**

Para sistemas de producción complejos con incertidumbre variable se propone el siguiente proceso de identificación y predicción dinámica de cuellos de botella.

#### **3.1.1 Análisis de incertidumbre en sistemas de producción serial**

En los sistemas de producción complejos, la incertidumbre es un factor que influye en la eficiencia, la estabilidad y la capacidad de respuesta del flujo productivo (Tang et al., 2024). Esta incertidumbre se puede manifestar tanto en la entrada de materiales como en los procesos internos y la salida de productos terminados.

Además, elementos propios del sistema, como condiciones operativas cambiantes o rutas de procesamiento no estandarizadas pueden generar una alta variabilidad en los tiempos de producción. La diversidad en los flujos y en los

requerimientos operativos se puede traducir en una carga desigual entre estaciones, provocando que los cuellos de botella no permanezcan en un único punto de la línea, sino que estos se desplacen dinámicamente a lo largo de la línea de producción.

Este comportamiento transitorio representa un reto para lograr su detección y gestión. Por tanto, se requiere de un modelo que represente la operación dinámica del sistema al incorporar fuentes de incertidumbre multivariable que afecten tanto la eficiencia como la estabilidad del flujo productivo. En este sentido, el uso de RN, en combinación con entornos de simulación con Arena, permite modelar la naturaleza dinámica y cambiante del sistema.

### 3.1.2 Cálculo del índice de cuello de botella (BI)

Se considera un conjunto  $K$  lotes que ingresan al sistema, con cada lote compuesto por  $B_k$  unidades. En el proceso  $i$ , se procesan  $C_i$  piezas, de las cuales  $f_i$  avanzan a la siguiente etapa y  $s_i$  son rechazadas o reprocesadas, cumpliéndose  $C_i = f_i + s_i \geq \sum_{k=1}^K B_k$ . El tiempo total de procesamiento se obtiene como la suma del tiempo efectivo ( $\sum_{j=1}^{s_i} T_{i,j}$ ) en todos los procesos.

El índice del tiempo efectivo  $\mu_{E,i}$  se calcula como la proporción de tiempo con valor agregado respecto al total de tiempo operativo del proceso  $i$ :

$$\mu_{E,i} = \frac{\sum_{j=1}^{s_i} T_{i,j}}{T_i} \times 100\% \quad [1]$$

Mientras que el índice de tiempo de producción  $\mu_{T,i}$  representa la participación del proceso  $i$  en el tiempo total del sistema:

$$\mu_{E,i} = \frac{T_i}{\sum_{i=1}^I T_i} \times 100\% \quad [2]$$

Finalmente, el índice de cuello de botella ( $Ib_i^t$ ), se define como la razón entre ambos indicadores. Para cada estación  $i$  en intervalos de tiempo  $t$ , se calcula:

$$Ib_i^t = \frac{\mu_{T,i}}{\mu_{E,i}} \quad [3]$$

El proceso con el valor más alto de  $Ib_i$  en un mismo periodo se identifica como el cuello de botella del sistema.

### 3.2. Modelo de simulación del sistema en Arena

Con el fin de representar y analizar el comportamiento dinámico del sistema, se hace uso de Arena versión 16.20.00 para desarrollar un modelo de simulación de la línea de producción. Para esto se define en primera instancia, la estructura del sistema productivo y la secuencia operativa de la línea de producción. Seguidamente, se integran los datos operativos necesarios tales como los tiempos de llegada de los insumos, las rutas de procesamiento, las distribuciones de los tiempos de ciclo, los porcentajes de desperdicio en las estaciones y las tasas de salida.

Para el seguimiento del desempeño del sistema, se incluye un módulo específico encargado de registrar atributos para cada entidad por estación. Una vez terminada la configuración del modelo, se ejecuta la simulación con el objetivo de obtener valores de dichos atributos. A continuación, se realiza una revisión detallada de los elementos involucrados en la simulación, así como sus relaciones.

En la Figura 1 se ilustra el diagrama para la línea de manufactura y reproceso; donde en la estación de inspección preliminar ( $W_0$ ), una proporción de las piezas son inmediatamente desechadas al no cumplir con los requisitos para su procesamiento, otra proporción inmediatamente cumplen los requisitos para su reutilización y la proporción final de las piezas que continúan con el proceso de remanufactura se dividen en dos caminos: piezas levemente rayadas y piezas biela con rectificado en el orificio de la cabeza grande.

Las piezas levemente rayadas, están listas para incorporarse a los siguientes siete procesos: bruñido ( $W_1$ ), prensado de bujes ( $W_2$ ), colocación de bujes ( $W_3$ ), fresado ( $W_4$ ), taladrado de orificios en la cabeza pequeña ( $W_5$ ), enderezado ( $W_6$ ) y limpieza ( $W_7$ ). En contraste, las piezas con orificio requieren de dos procesos antes de poder llegar a la estación de bruñido: limpieza eléctrica ( $W_8$ ) y Recubrimiento electrolítico por cepillo ( $W_9$ ). Si luego del proceso de remanufactura, alguna de las piezas no cumple con los requisitos de uso y calidad de una pieza remanufacturada ( $P_3$ ), estas son desechadas ( $P_1$ ), más si fueron seleccionadas inmediatamente para reutilización se reconocen como ( $P_2$ ). En esta simulación, se incluyen eventos y rutas típicas de la remanufactura donde en caso existe: procesos secuenciales, saltos de operación y rutas de retrabajo.

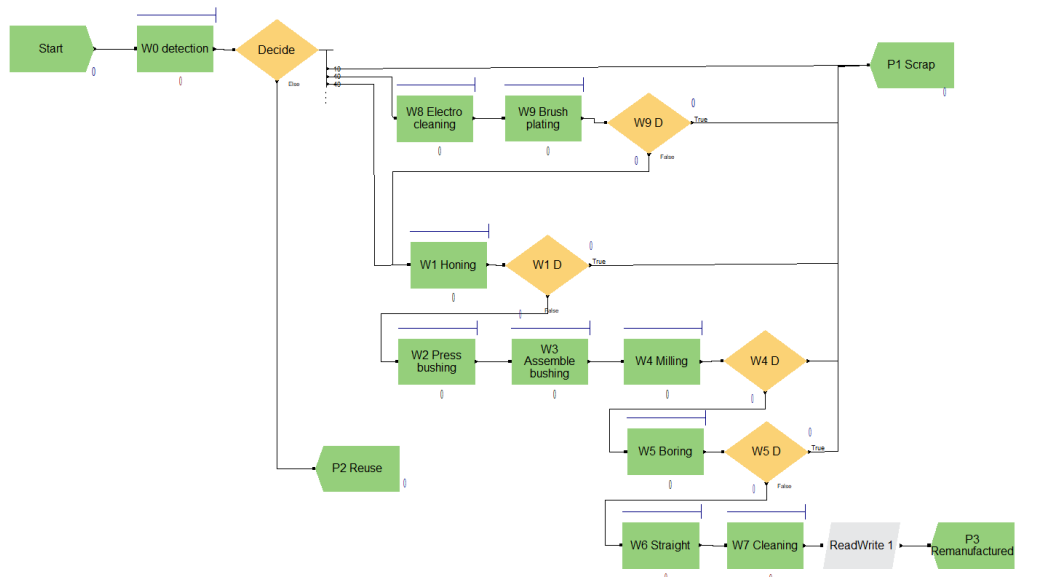


Figura 1. Configuración de bloques para simulación en Arena.

Para la simulación de Arena y su correcto estudio del sistema, se establecen los siguientes parámetros: a) Al sistema ingresa 1 pieza por minuto, b) el tiempo de manipulación manual entre cada proceso es de 0,5 minutos, c) el tiempo de gestión y mantenimiento de fallos se considera despreciable, d) Existe una zona de almacenamiento intermedio (buffer) entre cada proceso, con capacidad infinita, e) El método de probabilidad de transición se utiliza para representar la ruta de procesamiento de las piezas. Esta probabilidad de transición entre procesos utilizada se puede consultar en la Tabla 1, acompañada de la distribución probabilística para su tiempo de procesamiento. Asimismo, se estableció una duración de 280 horas para el modelo; y su periodo de calentamiento es de 10 horas para 10 corridas. El modelo completo de la simulación se encuentra como Anexo 1.

Tabla 1. Distribuciones estadísticas de procesos, rutas y su probabilidad de transición

Ruta de Proceso	Probabilidad de Transición	Distribución del tiempo de proceso / minuto
W0→W1	0.4	EXPO(1)
W0→P1	0.1	
W0→W8	0.4	
W0→P2	0.1	
W1→W2	0.99	NORM(0.5,0.1)
W1→P1	0.01	
W2→W3	1	TRIA(0.97,1,1.03)
W3→W4	1	TRIA(0.5,1,1.5)
W4→W5	0.9	NORM(1,0.1)
W4→P1	0.1	
W5→W6	0.9	EXPO(2)
W5→P1	0.1	
W6→W7	1	NORM(0.1,0.01)
W7→W8	1	NORM(1,0.1)
W8→W9	1	NORM(0.5,0.1)
W9→W1	0.9	UNIFORME(1.98,2.05)
W9→P1	0.1	

### 3.3. Modelado de la Red Neuronal

Para la predicción del BI por estación, se desarrolló una red neuronal artificial de tipo supervisado, enfocada en problemas de regresión multivariada, donde la variable objetivo es un vector de diez salidas continuas correspondiente al BI en cada una de las estaciones de trabajo (W0 a W9) de un sistema de manufactura.

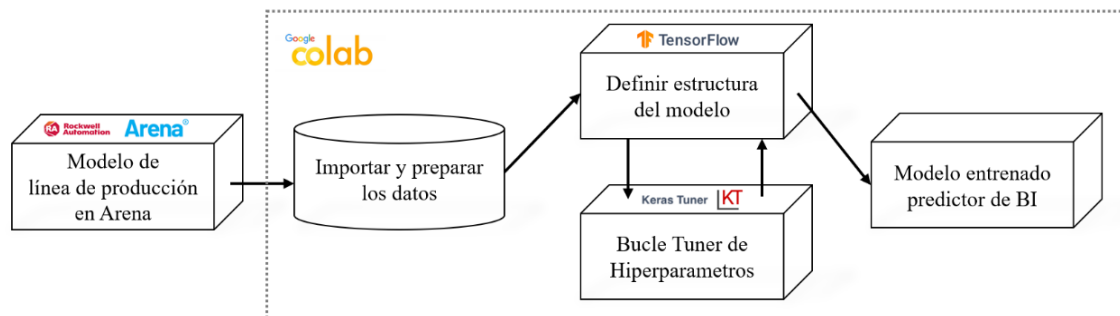


Figura 2. Flujo metodológico para la predicción del índice de cuello de botella

#### 3.3.1 Arquitectura del modelo

El modelo fue implementado utilizando la biblioteca TensorFlow, bajo una arquitectura densa (fully connected). La capa de entrada recibe un conjunto de variables que describen el estado del sistema de manufactura, incluyendo: cantidad de productos, periodo del proceso y los tiempos acumulados en cada estación. Estas variables fueron escaladas utilizando normalización tipo Z-score para mejorar la estabilidad y la eficiencia del proceso de entrenamiento.

La arquitectura interna del modelo, incluyendo la cantidad de capas ocultas, el número de neuronas por capa, la función de activación y la tasa de regularización mediante Dropout, no fue definida a priori, sino que se ajustó automáticamente mediante un proceso de sintonización de hiperparámetros. Este proceso fue realizado con el paquete Keras Tuner, bajo un enfoque de búsqueda aleatoria (Random Search), explorando múltiples configuraciones para identificar la combinación que produjera el menor error de validación.

El modelo se entrenó con el optimizador Adam, y la función de pérdida utilizada fue el error cuadrático medio (MSE, por sus siglas en inglés). Como métrica principal de evaluación se empleó el error absoluto medio (MAE, por sus siglas en inglés), al ser más interpretable y robusto frente a valores atípicos en los datos. La salida del modelo es un vector continuo de 10 dimensiones, que permite anticipar el grado de congestión esperado en cada estación de trabajo, habilitando así análisis predictivos y decisiones proactivas en la operación de la línea. En el Anexo 3 se encuentra el código de Python.

#### 3.3.2 Evaluación del modelo

La red neuronal se evaluó utilizando el conjunto de prueba, mediante el MAE para cada estación. Se usaron diagramas de caja (*boxplots*) para visualizar la distribución del error por estación y detectar posibles patrones de variabilidad. También se calculó el MSE en las primeras 10 observaciones, con el fin de analizar el desempeño a nivel individual. Por último, se graficaron las predicciones del BI para las tres estaciones con mayor BI, lo que permitió observar visualmente la precisión del modelo en una secuencia temporal específica. En el Anexo 2 se encuentra el código de Python.

#### 3.3.3 Tuning de hiperparámetros

Para mejorar el desempeño del modelo, se realizó un proceso de ajuste de hiperparámetros mediante búsqueda aleatoria (Random Search) utilizando la librería Keras Tuner. Se evaluaron diferentes combinaciones de parámetros clave, incluyendo el número de capas, cantidad de neuronas por capa, función de activación, tasa de aprendizaje, uso de regularización mediante Dropout, epochs y tamaño del batch.

El criterio de selección fue minimizar el MAE en validación. Se implementó un callback personalizado que detenía el entrenamiento si el modelo alcanzaba un MAE inferior a 0.001, con el objetivo de evitar sobre entrenamiento (overfitting) innecesario. En el Anexo 2 se encuentra el código de Python.

Los resultados del tuning se resumieron en una tabla ordenada por desempeño, permitiendo identificar las configuraciones más prometedoras para su posterior validación manual.

## 4. Resultados y discusión

### 4.1 Resultados del Ajuste de Hiperparámetros

Se realizó una búsqueda aleatoria de combinaciones de hiperparámetros para entrenar una red neuronal densa orientada a la predicción del índice de cuello de botella (BI) en función de variables de entrada del proceso. El rendimiento de cada configuración fue evaluado utilizando el error absoluto medio (MAE) en el conjunto de validación. Los 10 mejores resultados obtenidos se resumen en la Tabla 2.

Tabla 2. Resultados del tuning de hiperparámetros ordenados por MAE

Número de capas	Neuronas en capa 1	Neuronas en capa 2	Método de activación	Epochs	Tamaño de batch	Tasa de aprendizaje	Tasa de Dropout	Valor de MAE
2	32	128	relu	70	32	0.01	0.5	0.009390309
1	32	32	tanh	30	16	0.01	0.2	0.009536828
2	32	32	relu	70	16	0.01	-	0.009543139
1	128	64	relu	50	32	0.01	0.5	0.009619092
1	128	96	tanh	30	32	0.01	0.1	0.009824576
1	128	64	relu	70	16	0.01	0.3	0.009854361
1	64	96	relu	50	16	0.01	0.2	0.009907999
2	96	32	relu	50	32	0.01	0.3	0.010971352
1	64	96	tanh	50	32	0.01	0.2	0.011805196
1	96	32	relu	70	16	0.01	0.3	0.011948629

Asimismo, se observa una mayor recurrencia de la función de activación ReLU en las configuraciones con menor error, lo que sugiere una mayor capacidad de generalización respecto a la función tanh. La presencia consistente de técnicas de regularización mediante dropout (en el rango de 0.2 a 0.5) refuerza la importancia de mitigar el sobreajuste en el modelo. En cuanto al tamaño de batch, los valores de 32 se asocian frecuentemente con menores errores, mientras que no se aprecia una tendencia clara en relación con el número de epochs, posiblemente debido a la aplicación de una estrategia de parada temprana.

Estos hallazgos permitieron delimitar una región de hiperparámetros de alto rendimiento, que sirvió como base para la selección del modelo final empleado en la siguiente etapa del estudio.

### 4.2 Resultados del Modelo de Red Neuronal

Tras el ajuste de hiperparámetros, se seleccionó la arquitectura con mejor desempeño, la cual consiste en una red neuronal de dos capas ocultas con 32 y 128 neuronas respectivamente, función de activación *ReLU*, una tasa de *dropout* del 0.5, tasa de aprendizaje de 0.01, y parámetros de entrenamiento de 70 *epochs* y tamaño de *batch* de 32. Esta configuración logró un error MAE de 0.00993. El resultado del modelo se encuentra en el Anexo 4.

La Figura 3 presenta la distribución del MAE por estación de trabajo. Se observa que las estaciones W2, W3, W4, W6, W7 y W8 presentan una baja mediana de error y escasa dispersión, lo cual sugiere una predicción precisa y consistente. En contraste, las estaciones W0, W1 y, particularmente, W5 exhiben mayor variabilidad y valores atípicos, lo que indica un mayor grado de incertidumbre en la predicción del índice de cuello de botella para esas estaciones.

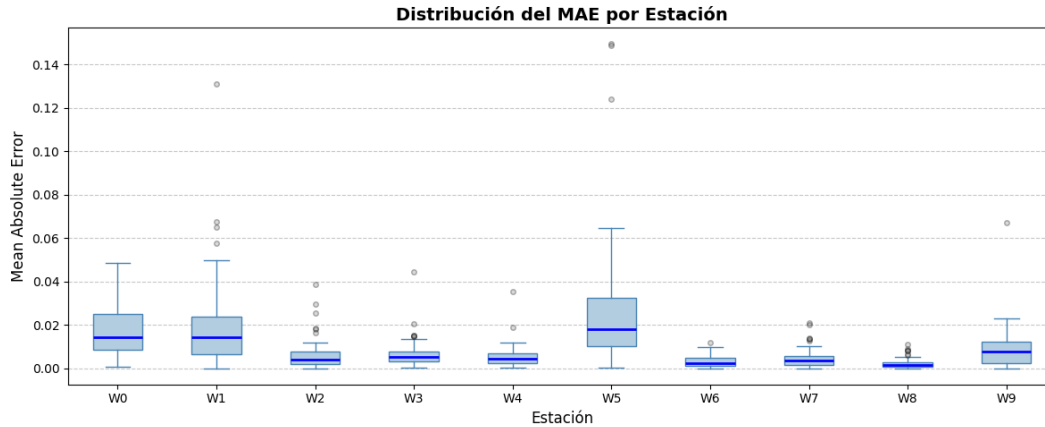


Figura 3. Distribución del MAE por estación de trabajo

Estos resultados validan la capacidad del modelo para predecir el comportamiento del índice de cuello de botella en distintas estaciones, permitiendo su uso como herramienta de apoyo para la toma de decisiones en sistemas de manufactura.

El modelo logra capturar no solo la magnitud promedio de los valores, sino también su comportamiento dinámico y las oscilaciones de la señal. Aunque existen ligeras discrepancias puntuales en los picos más pronunciados, la tendencia general es reproducida adecuadamente, lo que demuestra la capacidad de la red neuronal para modelar la secuencia temporal del BI en esta estación crítica. Este resultado es especialmente relevante, ya que W5 fue identificada previamente como una de las estaciones con mayor error absoluto, por lo que lograr una predicción coherente a lo largo del tiempo representa una mejora sustancial en la caracterización de cuellos de botella en sistemas complejos.




Figura 4. Comparación entre los valores originales y los valores predichos del índice de cuello de botella (BI) para la estación W5

Por otro lado, la Figura 4 muestra el comportamiento del BI predicho para las estaciones W0, W1 y W5 en los índices de muestra del 20 al 39. En esta visualización se aprecia que la red neuronal logra capturar adecuadamente las fluctuaciones del BI, especialmente para W0 y W5, aunque W1 presenta mayor variabilidad y amplitud en los valores predichos. Esto podría estar asociado a una dinámica más compleja en dicha estación o a una menor representatividad en los datos de entrenamiento.






Figura 5. Aplicación a cuellos de botella dinámicos

Este comportamiento es consistente con el fenómeno conocido como bottleneck shifting, en el cual la estación crítica del proceso varía debido a la interacción de múltiples factores operativos. El cruce entre las curvas predichas para cada estación refleja estos desplazamientos, los cuales pueden tener implicaciones significativas en la planificación y toma de decisiones operativas. La capacidad del modelo para anticipar estos cambios dinámicos permite una gestión más proactiva de los recursos y una mayor resiliencia del sistema ante variaciones en la carga de trabajo.

## 5. Mejoras y Futuras Líneas de Investigación

A partir de la revisión del estado del arte y el desarrollo del modelo, se identifican diversas oportunidades para fortalecer y ampliar el enfoque propuesto. Una de las más relevantes es la necesidad de profundizar la identificación las causas asignables al error para las estaciones con un enfoque estadístico.

A pesar de los resultados prometedores, este estudio presenta algunas limitaciones que deben ser consideradas. En primer lugar, el modelo fue entrenado y evaluado utilizando datos generados a partir de simulaciones, lo cual, si bien permite controlar las condiciones del sistema, puede limitar la generalización de los resultados a entornos reales donde existen fuentes de ruido y variabilidad no modeladas.

Además, la arquitectura utilizada fue una red neuronal densa, la cual no explora de manera explícita la estructura temporal de los datos, como podrían hacerlo modelos recurrentes o basados en atención. Por tanto, una línea de trabajo futuro sería explorar arquitecturas como LSTM o Transformers para mejorar la capacidad de captura de dependencias de largo plazo. Asimismo, sería valioso validar el modelo con datos provenientes de plantas reales, incorporando eventos exógenos, cambios de turno, mantenimiento o interrupciones. Finalmente, la integración del modelo en sistemas de apoyo a la decisión en línea, con retroalimentación continua, representa una oportunidad para avanzar hacia operaciones más inteligentes y resilientes.

## 6. Conclusiones

A partir del ajuste de hiperparámetros se escogió una arquitectura compuesta por dos capas ocultas con 128 y 32 neuronas respectivamente, activación *relu*, una tasa de aprendizaje de 0.01, y un esquema de entrenamiento de 70 epochs con tamaño de batch de 32. Esta configuración alcanzó un error absoluto medio de 0.00939, lo cual evidencia un buen desempeño del modelo para predecir con precisión el índice de cuello de botella en distintos puntos del sistema. Una vez entrenado, este modelo puede ser implementado operativamente como una herramienta de monitoreo predictivo en entornos industriales. Por ejemplo, puede integrarse con sistemas SCADA o MES para recibir variables de proceso en tiempo real, ejecutar predicciones de BI y generar alertas ante posibles desplazamientos de cuellos de botella, facilitando así la toma de decisiones proactiva en la asignación de recursos o la configuración de líneas de producción.

Frente a métodos tradicionales de predicción de series de tiempo, este enfoque demostró ventajas concretas: no se requirió asumir linealidad, estacionariedad ni estructuras específicas de ruido. Además, los gráficos de predicción evidenciaron el fenómeno de *bottleneck shifting*, particularmente útil para la toma de decisiones operativas en tiempo real. No obstante, el modelo aún presenta limitaciones, por ejemplo, su entrenamiento depende de la calidad y representatividad de los datos simulados, y su aplicación en entornos reales requerirá validación adicional. A pesar de ello, los resultados obtenidos abren la oportunidad de incorporar técnicas basadas en inteligencia artificial para la

gestión predictiva de cuellos de botella, lo cual puede traducirse en mejoras significativas en eficiencia, planificación de recursos y reducción de tiempos de respuesta ante variabilidad operativa.

## 7. Referencias

- Box, G. E. P., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M. (2015). *Time Series Analysis: Forecasting and Control* (5th ed.). John Wiley & Sons.
- Frazzon, E. M., Kück, M., & Freitag, M. (2018). Data-driven production control for complex and dynamic manufacturing systems. *CIRP Annals*, 67(1), 515–518. <https://doi.org/10.1016/j.cirp.2018.04.033>
- Goldratt, E. M., & Cox, J. (2004). *The Goal: A Process of Ongoing Improvement* (3rd ed.). North River Press
- Hopp, W. J., & Spearman, M. L. (2008). *Factory Physics* (3rd ed.). McGraw-Hill.
- Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and Practice* (3rd ed.). OTexts.
- Iravani, Seyed M. R. 2021. “Throughput.” Chap. 2.2 in *Operations Engineering and Management: Concepts, Analytics, and Principles for Improvement*. 1st ed. New York: McGraw Hill. <https://www.accessengineeringlibrary.com/content/book/9781260461831/toc-chapter/chapter2/section/section12>
- Lai, X., Shui, H., Ding, D., & Ni, J. (2021). Data-driven dynamic bottleneck detection in complex manufacturing systems. *Journal of Manufacturing Systems*, 60, 662–675. <https://doi.org/10.1016/j.jmsy.2021.07.016>
- Li, J., Chang, Q., & Ni, J. (2009). Data driven bottleneck detection of manufacturing systems. *International Journal of Production Research*, 47(18), 5019–5036. <https://doi.org/10.1080/00207540802075641>
- Lindberg, C., Tan, S., Yan, J., Starfelt, F. 2015, "Key Performance Indicators Improve Industrial Performance", *Energy Procedia*, vol. 75, pp. 1785-1790. <https://doi.org/10.1016/j.egypro.2015.07.474>
- Lepenioti K, Pertselakis M, Bousdekis A., et al (2020). Machine Learning for Predictive and Prescriptive Analytics of Operational Data in Smart Manufacturing. *Advanced Information Systems Engineering Workshops*. 2020 Apr 29; 382:5–16. [https://doi.org/10.1007/978-3-030-49165-9\\_1](https://doi.org/10.1007/978-3-030-49165-9_1)
- Muchiri, P., & Pintelon, L. (2008). Performance measurement using overall equipment effectiveness (OEE): literature review and practical application discussion. *International Journal of Production Research*, 46(13), 3517-3535. <https://doi.org/10.1080/00207540601142645>
- Roser, C., Nakano, M., & Tanaka, M. (2002). *Throughput analysis for flow shops with bottlenecks*. *International Journal of Production Research*, 40(6), 1349–1361. <https://doi.org/10.1080/00207540110091688>
- Subramaniyan, M., Skoogh, A., Bokrantz, J., Sheikh, M. A., Thürer, M., & Chang, Q. (2021). Artificial intelligence for throughput bottleneck analysis – State-of-the-art and future directions. *Journal of Manufacturing Systems*, 60, 734–751. <https://doi.org/10.1016/j.jmsy.2021.07.021>
- Subramaniyan, M., Skoogh, A., Salomonsson, H., Bangladore, P., & Bokrantz, J (2018). A Data-Driven Algorithm to Predict Throughput Bottlenecks in a Production System Based on Active Periods of the Machines. *Computers & Industrial Engineering*, 125, 533-544. <https://doi.org/10.1016/j.cie.2018.04.024>
- Tang, J., Dai, Z., Jiang, W., Wu, X., Zhuravkov, M. A., Xue, Z., & Wang, J. (2024). A Comprehensive Review of Theories, Methods, and Techniques for Bottleneck Identification and Management in Manufacturing Systems. *Applied Sciences*, 14(17), 7712. <https://doi.org/10.3390/app14177712>
- Xue, Z.; Li, T.; Peng, S.; Zhang, C.; Zhang, H. A Data-Driven Method to Predict Future Bottlenecks in a Remanufacturing System with Multi-Variant Uncertainties. *J. Cent. South Univ.* 2022, 29, 129–145. <https://doi.org/10.1007/s11771-022-4906-z>
- West, N., Schwenken, J., & Deuse, J. (2023). Data-Driven Approach for Diagnostic Analysis of Dynamic Bottlenecks in Serial Manufacturing Systems. *arXiv preprint arXiv:2306.16120*. <https://arxiv.org/abs/2306.16120>

## 8. Anexos

Anexo 1. Modelo de Arena

Anexo 2. Base de datos de entrenamiento

Anexo 3. Código de Python para generar el modelo

Anexo 4. Modelo Realizado

## Biografías

**Priscila Arrieta Salazar:** Estudiante de cuarto año de la carrera de Ingeniería Industrial de la Universidad de Costa Rica. Posee interés en áreas como Simulación, Ingeniería de Operaciones y Gestión de la Calidad. Cuenta con experiencia en la ejecución de proyectos en distintas áreas: Diseño del Trabajo e Ingeniería de Factores Humanos en una empresa del sector alimentario dedicada a la elaboración de mermeladas y jugos naturales; Ingeniería de Calidad en una empresa del sector alimentario enfocada en la producción de elaboración de mantequillas a base de semillas; Gestión de la Calidad mediante auditorías internas para la implementación de la norma ISO 9001 en una empresa del sector construcción especializada en obras de infraestructura; y Logística de la Cadena de Valor con énfasis en gestión de inventarios y operaciones de almacenamiento en una empresa del sector comercial dedicada a la distribución de productos de limpieza.

**Nicolás Cortés Malaspina:** Estudiante de cuarto año de la carrera de Ingeniería Industrial de la Universidad de Costa Rica. Posee interés en áreas como Simulación, Ingeniería de Operaciones, Investigación de Operaciones, Robótica y Diseño de Experimentos. Con experiencia en realización de proyectos en áreas como Gestión de la Calidad en auditorías internas para la implementación de la norma ISO 9001, Ingeniería de Calidad, Diseño del Trabajo e Ingeniería de Factores, Logística de la Cadena de Valor. También ha sido asistente en el curso de Simulación y realizado pasantías en áreas ingenieriles.

**María Laura Jiménez:** Estudiante de cuarto año de la carrera de Ingeniería Industrial de la Universidad de Costa Rica. Sus principales intereses de investigación yacen en: Simulación, Gestión de Calidad. Ingeniería de Operaciones e Investigación de Operaciones. Posee experiencia en proyectos de mejora continua en las áreas de Logística de la Cadena de Valor, Gestión de Calidad y Gestión de Mantenimiento en empresas locales de distintas industrias: farmacéutica, manufactura de vestimenta y comercio al por menor. Actualmente se desempeña en el área de “Management Consulting” bajo una firma internacional.

**Treisy Vargas:** Estudiante de 4to año de la carrera de Ingeniería Industrial de la Universidad de Costa Rica. Posee interés en áreas como Simulación, Ingeniería de Operaciones y Diseño de Experimentos. Con experiencia en realización de proyectos en áreas como Gestión de la Calidad en auditorías internas para la implementación de la norma ISO 9001 en la Escuela de Administración de Negocios de la Universidad de Costa Rica, Ingeniería de Calidad en empresa privada productora de panes y postres artesanales, Diseño del Trabajo e Ingeniería de Factores Humanos en empresa privada productora de dispositivos médicos, Logística de la Cadena de Valor con experiencia en manejo de almacenes especialmente, proyecto realizado en empresa privada importadora de aires acondicionados.